Examen Laboratorio de Análisis de Datos

Informe de trabajo

Alumnos: Martínez, Matías; Videla, Santiago

Estructura:

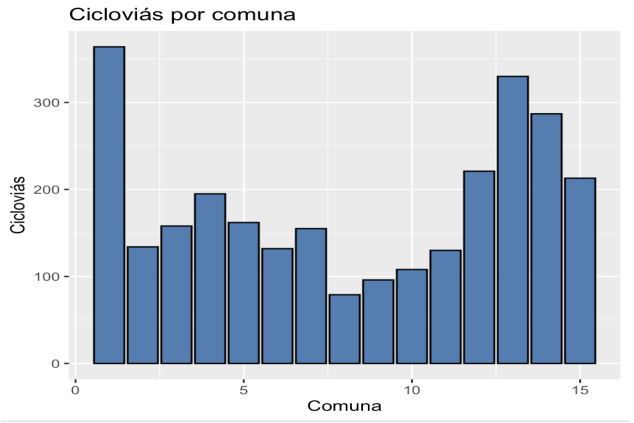
Este informe está dividido en tres secciones. La primera es el informe del ejercicio de análisis de datos. La segunda, del ejercicio de econometría. Por último está la sección del ejercicio de simulación, que en nuestro caso es la representación del juego de mesa conocido como T.E.G

Ejercicio Análisis:

Nos piden que elijamos una base de datos, y elegimos una de la página del gobierno de CABA, donde se muestran los datos de las distintas ciclovías de la ciudad. Luego de descargar la base, con las herramientas de R studio (readr, readxl, tydiverse y ggplot2) hicimos los incisos.

1) Lo primero que nos planteamos fue cómo se distribuyen geográficamente las ciclovías en CABA, osea, cuáles comunas tenían más y menos. Para ello, con las herramientas de *tydiverse*, creamos una nueva tabla *cantidad_por_comuna* agrupando las ciclovías por comuna y sumando cuántas veces aparece cada una de ellas, los resultados son los siguientes. Además, usando *ggplot* hicimos un gráfico de barras.

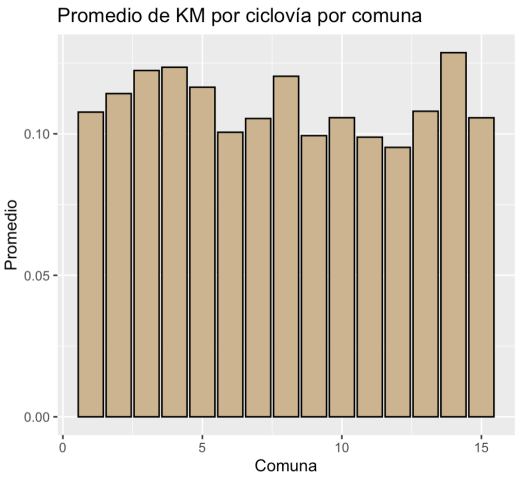
```
# A tibble: 6 × 2
  comuna cantidad
   <dbl>    <int>
1      1      364
2     13      330
3     14      287
4     12      221
5     15      213
6      4      195
```



2) Luego, nos preguntamos por el ratio de kilómetros de ciclovía por cantidad de las mismas, que nos da información sobre la composición geográfica de esos barrios y la inversión que tienen en este aspecto.

Para ello, con el comando *summarise* que también nos sirvió para la cantidad, hacemos la suma de longitudes de ciclovías por comuna (dividido 1000 ya que están en metros). Con *mutate* hicimos una columna dividiendo justamente estas variables y hacemos el ratio buscado. De la misma forma, graficamos.

```
# A tibble: 6 × 4
  comuna cantidad    km promedio
   <dbl>    <int> <dbl>    <dbl>
1     14      287 36.9     0.129
2      4      195 24.1     0.124
3      3      158 19.3     0.122
4      8       79  9.51    0.120
5      5      162 18.9     0.116
6      2      134 15.3     0.114
```

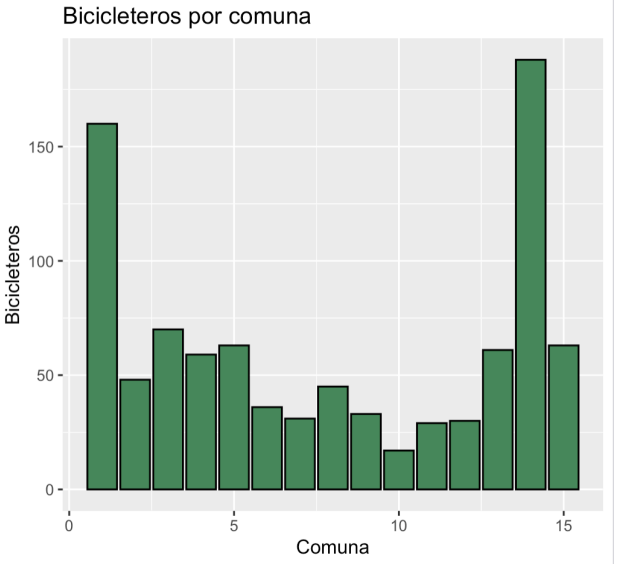


Observamos que a pesar de ser la comuna con más ciclovías, la número 1 tiene un ratio promedio, mientras por otro lado la 14 se mantiene entre los valores máximos de ambas variables. Esto nos puede contar sobre la inversión en esta comuna en relación a la anterior.

3) Por último, nos interesa ver la distribución de bicicleteros, ya que son una manera muy razonable de detectar dónde hay más bicis, es decir, las comunas donde más se usan. Primero debemos descargar estos datos, de un excel por lo que usamos otra herramienta (*readxl)*. Debido a una diferencia en cómo estaban anotados los datos, tuvimos que usar comandos para modificarlos, los cuales están explicados en el script.

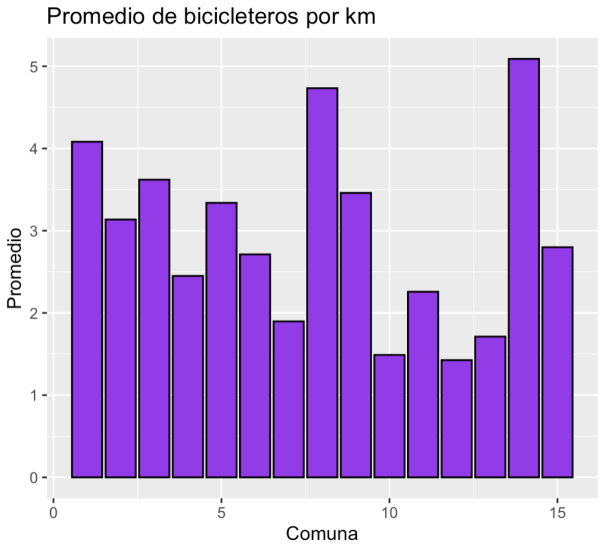
De manera análoga al primer inciso, hacemos la tabla y el gráfico.

```
# A tibble: 6 × 2
  comuna cantidad_bicicleteros
   <dbl>                 <int>
1     14                   188
2      1                   160
3      3                    70
4      5                    63
5     15                    63
6     13                    61
```



Teniendo estos datos, nos interesamos por el ratio de bicicleteros por km, lo que nos puede decir cuán "vacías" están las ciclovías. Para ello hacemos un *join* con los datos y, una vez más, con *summarise* hacemos una columna con el ratio que nos interesa.

```
# A tibble: 6 × 2
  comuna prm_bic_km
   <dbl>      <dbl>
1     14       5.09
2      8       4.73
3      1       4.08
4      3       3.62
5      9       3.46
6      5       3.34
```



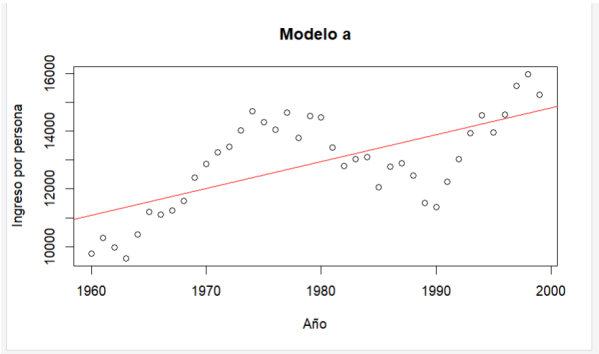
Ejercicio Econometría:

1) En el inciso uno nos pedían graficar el ingreso por persona de Argentina. Primero, filtramos los datos (gapminder) para que solo tenga en cuenta a Argentina. A continuación utilizamos el comando "ggplot", visto en clase, poniendo en el eje x los años y en el eje y el ingreso por persona. Finalmente, agregamos las etiquetas a los ejes. El resultado es el siguiente:

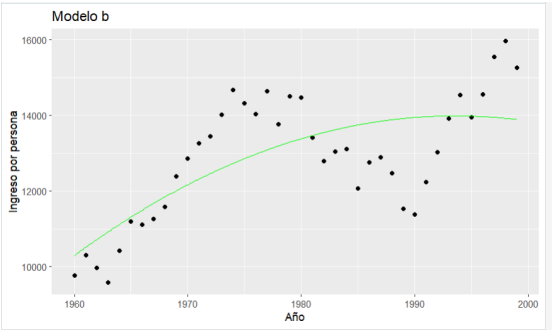


Podemos notar como tiene una tendencia a la suba del ingreso por persona. Sin embargo, este no es constante, presenta bajadas en algunos años.

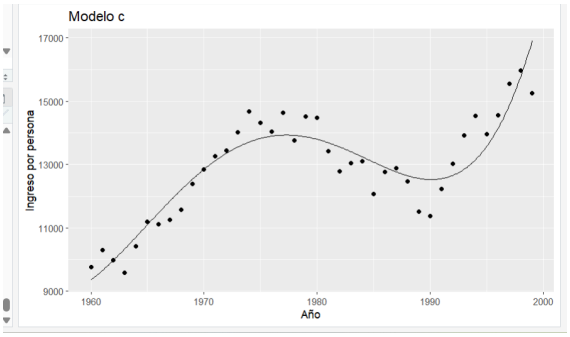
2) En el segundo inciso, en primer lugar separamos los primeros cuarenta años de Argentina (para la prueba) utilizando el filtro (year<2000). A continuación, estimamos de manera lineal el ingreso por persona. Los años son la variable explicativa y el ingreso por persona es la variable explicada. Hacemos lo mismo para estimar de manera cuadrática y polinómica grado diez.
A continuación obtenemos los siguientes resultados:



Regresión lineal



Regresión cuadrática



Regresión polinómica grado diez

Al comparar los tres modelos estimados, observamos que el modelo lineal presenta una tendencia creciente, aunque no consigue capturar los cambios del ingreso por persona de Argentina. El modelo cuadrático incorpora curvatura y permite representar mejor algunos cambios en la evolución del ingreso. Sin embargo, el modelo polinómico de grado 10 es el que presenta un mejor ajuste visual a los datos observados, debido a su mayor flexibilidad.

3) a) Para resolver el inciso 3(a), primero seleccionamos cinco países sudamericanos: Argentina, Brasil, Uruguay, Chile y Colombia. Utilizamos filter() para quedarnos únicamente con las observaciones de esos países y select() para conservar las variables país, año e ingreso por persona. Luego usamos pivot_wider() para

reorganizar los datos, colocando cada país en una columna y los años en las filas. Finalmente, aplicamos cor() para obtener la matriz de correlaciones entre los ingresos por persona de los cinco países. El resultado es el siguiente:

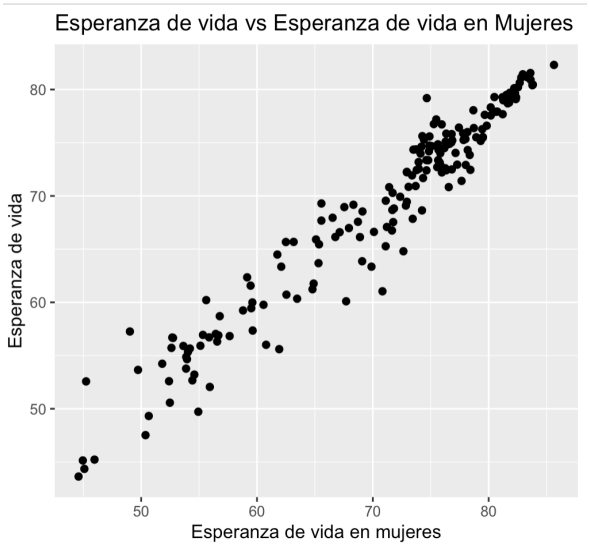
```
                year Argentina    Brazil     Chile  Colombia   Uruguay
year      1.0000000 0.7597685 0.9446633 0.9039794 0.9867272 0.9290503
Argentina 0.7597685 1.0000000 0.7951110 0.7650413 0.8073113 0.8291831
Brazil    0.9446633 0.7951110 1.0000000 0.7717164 0.9600286 0.8713498
Chile     0.9039794 0.7650413 0.7717164 1.0000000 0.8962301 0.9407932
Colombia  0.9867272 0.8073113 0.9600286 0.8962301 1.0000000 0.9504906
Uruguay   0.9290503 0.8291831 0.8713498 0.9407932 0.9504906 1.0000000
>
```

3) b) Para resolver el inciso 3(b), primero calculamos la variación porcentual anual del ingreso por persona de cada país. Para ello, utilizamos group_by() para agrupar las observaciones por país y mutate() para crear la variable crecimiento, calculando la diferencia entre el ingreso actual y el del año anterior, dividida por el ingreso del año anterior. La función lag() permite obtener ese valor del año previo. Luego, mediante pivot_wider(), reorganizamos los datos para que cada país quede en una columna. Finalmente, utilizamos cor() para calcular la matriz de correlaciones entre las tasas de crecimiento anual de los cinco países. El resultado es el siguiente:

```
                year  Argentina       Brazil       Chile    Colombia   Uruguay
year       1.00000000 0.03027374 -0.221028098 0.199355894 -0.08288698 0.2447490
Argentina  0.03027374 1.00000000  0.272052233 0.169198858  0.39965973 0.5127562
Brazil    -0.22102810 0.27205223  1.000000000 0.006129268  0.57321590 0.2779881
Chile      0.19935589 0.16919886  0.006129268 1.000000000  0.30091721 0.3655066
Colombia  -0.08288698 0.39965973  0.573215900 0.300917210  1.00000000 0.4311366
Uruguay    0.24474902 0.51275619  0.277988119 0.365506633  0.43113664 1.0000000
>
```

Por ejemplo, tomando el caso de Argentina y Brasil, podemos ver que en la primera matriz el resultado es 0.79 y en la segunda 0.27. Esto nos permite concluir que Argentina y Brasil presentan una tendencia similar en el crecimiento del ingreso (primera tabla) pero difieren en los años en donde este se produce (segunda tabla).

5) Para este inciso ya nos piden filtrar únicamente un año, y elegimos el 2005. El gráfico lo hicimos con ggplot como veníamos haciendo desde el ejercicio de análisis.



Es a simple vista observable la relación positiva entre ambas variables, de tal manera que parece una línea perfecta y=x.

6) Hacemos un modelo lineal donde explicamos *life_expectancy* con *life_expectancy_female*. Usamos el comando *lm()* y, una vez definido, generamos un resumen del mismo con el comando *summary*.

```
Residuals:
   Min     1Q Median     3Q    Max
-8.244 -1.351  0.303  1.138  7.089

Coefficients:
                       Estimate Std. Error t value Pr(>|t|)
(Intercept)             7.19162    1.16860   6.154 4.69e-09 ***
life_expectancy_female  0.87662    0.01646  53.271  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.308 on 182 degrees of freedom
  (3 observations deleted due to missingness)
Multiple R-squared:  0.9397,    Adjusted R-squared:  0.9394
F-statistic:  2838 on 1 and 182 DF,  p-value: < 2.2e-16
```

Observamos que el R cuadrado es casi 1, lo que nos dice que la variable tiene un peso explicativo muy fuerte. Podemos interpretar esto de la siguiente manera: la esperanza de vida de las mujeres representa un poco más de un medio de la esperanza de vida en general, por lo que sólo observando la primera uno se puede hacer una muy buena idea de la segunda.

7) Hacemos el test de hipótesis que nos piden. Definimos el coeficiente como *beta1_hat*, y al error *se_beta1*. Definimos también el número de observaciones y los grados de libertad. Al resultado de la división lo llamamos *t_stat*, y representa nuestro

test. Sacamos el p-value con el comando en el script y al observar vemos que es casi 1, lo que indica que la hipótesis está desacertada. Tiene sentido, ya que al existir hombres, es imposible explicar la esperanza de vida total solo observando a las mujeres.

8) Ahora hacemos el modelo agregando la variable *income_per_person*, que representa el ingreso per cápita, de manera análoga al inciso 6. Así, obtenemos los siguientes resultados:

```
Residuals:
    Min      1Q  Median      3Q     Max 
-7.9174 -1.1540  0.2307  1.2289  6.8620 

Coefficients:
                         Estimate Std. Error t value Pr(>|t|)    
(Intercept)            8.444e+00  1.293e+00   6.530 6.44e-10 ***
life_expectancy_female 8.538e-01  1.940e-02  44.010  < 2e-16 ***
income_per_person      2.283e-05  1.053e-05   2.168   0.0315 *  
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.285 on 181 degrees of freedom
  (3 observations deleted due to missingness)
Multiple R-squared:  0.9413,    Adjusted R-squared:  0.9406 
F-statistic:  1450 on 2 and 181 DF,  p-value: < 2.2e-16
```

Notamos que B1, que representa el efecto de un aumento en la esperanza de vida para las mujeres, es mucho mayor que B2, el efecto del aumento en el ingreso por persona. Además, si vemos el R cuadrado, vemos que es muy similar al del modelo anterior, lo que nos muestra que la nueva variable aporta poco, y no es necesario ni conveniente incluirla si nos da más trabajo.

9) Para el nuevo modelo, intentaremos explicar la esperanza de vida a partir de las condiciones de los niños. Para ello, usaremos las variables *child_per_woman*, que nos dirá cómo aumenta la cantidad de niños en el tiempo, *child_mortality* y la variable generada *income_per_child*, una medida de condición económica que creamos a partir del ingreso por persona y los hijos por mujer, con las herramientas de *tydiverse*, de manera similar al ejercicio de análisis de datos.

De manera análoga a los incisos anteriores, hacemos el modelo lineal:

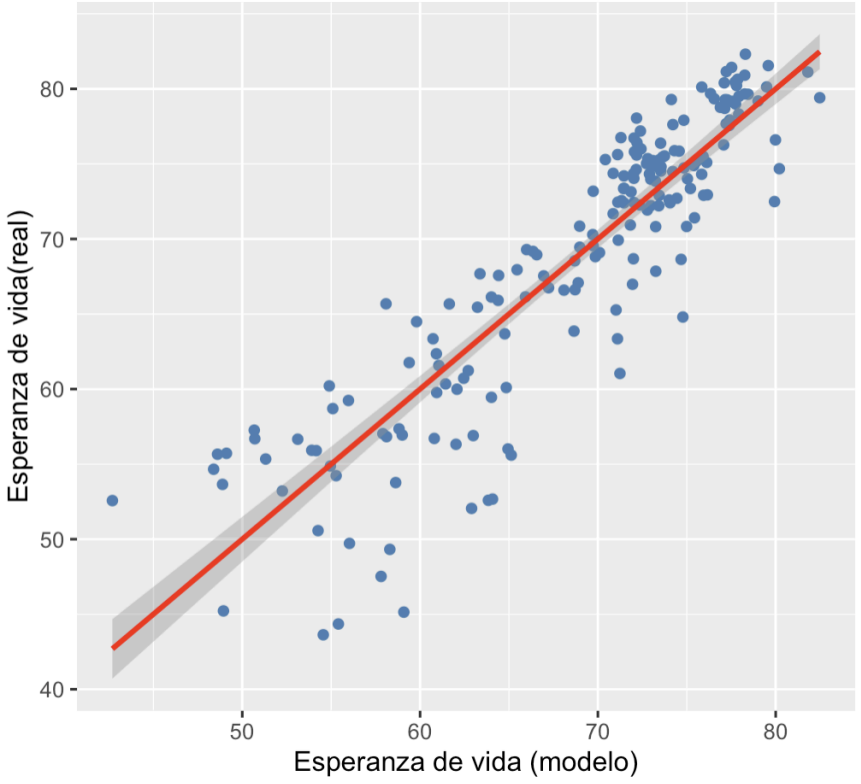
```
Residuals:
     Min       1Q   Median       3Q      Max
-13.9459  -1.5091   0.8776   2.6290   9.8745

Coefficients:
                     Estimate Std. Error t value Pr(>|t|)
(Intercept)         7.433e+01  1.004e+00  74.053  < 2e-16 ***
children_per_woman  3.633e-01  4.063e-01   0.894    0.372
child_mortality    -1.660e-01  1.410e-02 -11.776  < 2e-16 ***
income_per_child    1.511e-04  3.509e-05   4.305 2.74e-05 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 4.19 on 180 degrees of freedom
Multiple R-squared:  0.8036,    Adjusted R-squared:  0.8003
F-statistic: 245.4 on 3 and 180 DF,  p-value: < 2.2e-16
```

B1 representa el efecto de que las mujeres tengan más hijos, B2 el efecto de un aumento en la mortalidad infantil (negativo, lógicamente), y B3 cómo aumenta la esperanza de vida a mayor niveles de ingreso por hijo, o ingreso familiar. El R cuadrado es menor al de modelo de esperanza femenina, pero el valor de 0,8 es bastante alto igual.

Para observar qué tan bueno es, le agregamos a los datos una columna *predict9* con las predicciones del modelo e hicimos un último gráfico comparando los datos reales con los estimados (ggplot):



Ejercicio de simulación (T.E.G.):

1) En el primer inciso, creamos la función *resultado_ataque*, la cual recibe, como input, la cantidad de dados que usan el atacante y el defensor y devuelve, como output, la cantidad de fichas perdidas por cada uno. En primer lugar, utilizamos el comando "sample", el cual selecciona números del uno al seis una cantidad n_atacante/defensor veces (es decir, de acuerdo a la cantidad de dados que utilice cada jugador).

Luego, a partir del "sort" los ordenamos de mayor a menor, para luego compararlos. Por último, utilizo un "for" que va desde uno hasta el mínimo de dados que tengan, junto con un "if", el cual condiciona en función de quien obtuvo el dado más alto. Finalmente, a partir del "return" obtenemos un vector con el resultado de las pérdidas de cada uno.

A continuación podemos ver un ejemplo aleatorio del uso de esta función:

```
> resultado_ataque(3,3)
atacante defensor
       2        1
```

El atacante pierde dos fichas y el defensor una. Es lógico que el atacante tienda a perder más cantidad de fichas porque ante un empate gana el defensor.

2) En el segundo inciso, creamos una función llamada *simular_batalla*, la cual recibe como argumentos la cantidad de fichas de cada uno de los jugadores y simula una batalla completa. Utilizamos el comando while, con el objetivo de imponer que la batalla se lleve a cabo siempre y cuando el atacante tenga más de una ficha y el defensor al menos una (estas son las reglas del juego).

Para imponer estas dos condiciones utilizamos el "&&". Luego calculamos los dados que va a tirar cada uno, los cuales salen del "min" entre 3 y la cantidad de fichas que tengan (en el caso del atacante hay que restarle una, no puede usar todas). Estas dos variables (llamadas *dados_a* y *dados_d*) son las que luego irán como input en la función previamente creada, *resultado_ataque*.

Definimos una nueva variable llamada "pérdidas", esta va a ser el output de la función *resultado_ataque*. Esta es un vector con dos números, primero las fichas que pierde el atacante y luego las que pierde el defensor. Por último, actualizamos sucesivamente las fichas del atacante/defensor (el input que recibe la función *simular_batalla*) restándole las pérdidas a la cantidad de fichas con las que ingresaron.

La batalla se detiene cuando se dejen de cumplir ambas condiciones del while. Finalmente, la función devuelve (a partir del “return”) un *True* si el defensor se queda con cero fichas (es decir, gana el atacante) y un *False* si ocurre lo contrario.

A modo de ejemplo, si cada uno ingresa con cinco fichas, se puede ver en la imagen que el resultado es False, es decir, gana el defensor (lo cual vuelve a ser lógico porque ante empate en números gana el defensor).

```
> simular_batalla(5,5)
defensor
   FALSE
```

3) En el inciso 3 creamos la función *probabilidad_ataque* que simulamos mil batallas en donde cada jugador empieza con cinco fichas. Para ello utilizamos el comando “replicate” el cual repite mil veces la función *simular_batalla*, con cinco fichas cada uno. Luego, obtenemos un vector con mil true/false (depende el resultado de la batalla). A esto lo llamamos “resultados”. Por último, llamamos una nueva función “probabilidad” que contabiliza el promedio de los resultados anteriores (uno si es true y cero si es false). El resultado del ejercicio es que esta probabilidad converge al 18%, es decir, si hacemos mil batallas en donde ambos tienen cinco fichas, un 18% gana el atacante y un 82% el defensor. Esto es lógico ya que en caso de que empaten los dados, el defensor se queda con la ficha, lo cual genera una gran ventaja.